

The background is a dark blue-tinted image of an industrial factory floor. In the center, the text 'UnISENAI' is prominently displayed. To the right of the text, there are several semi-transparent circular graphics that look like gauges or data displays. One gauge shows '80%', another shows '79%', and a larger one shows '94%'. There are also some faint numbers like '01-1000' visible on the background elements.

UnISENAI

O FUTURO COMEÇA
POR VOCÊ!

Aula 3 - Regressão

Prof. Matheus Vanzan

Machine Learning

UniSENAI

Conteúdo

- Revisão
- Definição de Algoritmos de Regressão
- Regressão Linear
- Regressão Polinomial
- Medidas de desempenho

Revisão

Revisão da Aula 1


Revisão

- O que é Machine Learning
- Tipos de Aprendizado (Supervisionado, Não supervisionado, Reforço)
- Treinamento de ML (pré-processamento, treino, avaliação)
- Exemplos de Classificação e Regressão
- Exemplo prático com dataset


Sistemas de Aprendizado



Supervisionado



Classificação
saída discreta (labels)



Regressão
saída numérica


Regressão

O que é Regressão?

- Algoritmo **supervisionado** para prever uma **variável contínua**
- Objetivo: encontrar uma **função** que melhor descreve a relação entre variáveis de **entrada** (*features*) e **saída** (*target*)

O que é Regressão?

- Algoritmo **supervisionado** para prever uma **variável contínua**
- Objetivo: encontrar uma **função** que melhor descreve a relação entre variáveis de **entrada** (*features*) e **saída** (*target*)




O que é Regressão?

- ➡ Algoritmo **supervisionado** para prever uma **variável contínua**
- ➡ Objetivo: encontrar uma **função** que melhor descreve a relação entre variáveis de **entrada** (*features*) e **saída** (*target*)

📌 Exemplos:

- Previsão de preço de imóveis 📌 saída: valor em R\$
- Previsão de temperatura 📌 saída: graus Celsius

Regressão



Regressão Linear

Regressão Linear Simples

- Modelo mais básico de regressão
- Estima uma relação **linear** entre uma variável independente (x) e a dependente (y)

Regressão Linear Simples

- Modelo mais básico de regressão
- Estima uma relação **linear** entre uma variável independente (x) e a dependente (y)

$$y = \beta_0 + \beta_1 x + \epsilon$$

Regressão Linear Simples

- Modelo mais básico de regressão
- Estima uma relação **linear** entre uma variável independente (x) e a dependente (y)


$$y = ax + b$$

$$y = \beta_0 + \beta_1 x + \epsilon$$


Regressão Linear Simples

$$y = \beta_0 + \beta_1 x + \epsilon$$

β_0 coeficiente linear
(valor de y para $x = 0$) β_0

β_1 coeficiente angular
(inclinação da reta)

ϵ erro/resíduo



Regressão Linear Simples

Como achar a **equação da reta** que melhor se aproxima dos pontos?

→ Minimizar a diferença entre os **valores previstos** e os **valores reais** (erro)

 Intuição:

- Se os pontos estão acima ou abaixo da reta, calculamos a **distância vertical**
- Elevamos ao quadrado para evitar cancelamentos (positivos/negativos)
- A melhor reta é aquela que gera a **menor soma** desses quadrados

Método dos Mínimos Quadrados

→ O modelo **não vai acertar** exatamente


todos os pontos (*nem queremos isso!*)

→ Calculamos um **erro médio** entre

valores reais e previstos



Quanto **menor** esse valor, **melhor** o
ajuste da reta!



$$\text{Erro} = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Método dos Mínimos Quadrados

→ Rápido e direto, mas só funciona bem


para datasets pequenos

→ Muito **custoso computacionalmente**

para datasets grandes

→ Solução mais moderna: **Método do**


Gradiente Descendente





$$\text{Erro} = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Método do Gradiente Descendente


- Ao invés de resolver o problema com uma **conta fechada**, usamos um método **iterativo**
- Começamos com valores **iniciais** para os coeficientes (β)
- Ajustamos passo a passo, seguindo a direção que mais **reduz o erro**



Método do Gradiente Descendente



Método do Gradiente Descendente



Regressão Linear Múltipla

- Extensão da Regressão Linear Simples
- Permite considerar **múltiplas variáveis** independentes ao mesmo tempo

Regressão Linear Múltipla

- Extensão da Regressão Linear Simples
- Permite considerar **múltiplas variáveis** independentes ao mesmo tempo

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n + \epsilon$$


Regressão Linear Múltipla

- Extensão da Regressão Linear Simples
- Permite considerar **múltiplas variáveis** independentes ao mesmo tempo


$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n + \epsilon$$

- 📌 Cada variável adiciona um “peso” (coeficiente) para compor o valor final

Regressão Linear Múltipla



PRÁTICA



Regressão Polinomial

- Relações entre variáveis **nem sempre** são lineares
- Uma reta ou plano pode não ser suficiente para explicar os dados
- A Regressão Polinomial cria novas variáveis a partir de potências e consegue ajustar curvas

Regressão Polinomial

- Relações entre variáveis **nem sempre** são lineares
- Uma reta ou plano pode não ser suficiente para explicar os dados
- A Regressão Polinomial cria novas variáveis a partir de potências e consegue ajustar curvas

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_n x^n + \epsilon$$

Regressão Polinomial

- Apesar do nome, o modelo continua sendo **linear nos parâmetros** (β)
- Isso significa que ainda usamos **mínimos quadrados**, só que com mais *features* (transformadas de x)

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_n x^n + \epsilon$$

Regressão Linear vs Polinomial



Comparação visual


- Linear: reta única
- Polinomial: curva ajustável



Intuição

- Polinômio de grau 1 👉 reta (Regressão Linear)
- Polinômio de grau 2 👉 parábola
- Polinômio de grau 3 👉 curvas em “S”

PRÁTICA



Overfitting e Underfitting

→ Underfitting (subajuste)

- Modelo muito simples, não consegue capturar o padrão dos dados.
- Ex: usar uma reta para dados claramente curvos.

→ Overfitting (sobreajuste)

- Modelo complexo demais, se ajusta até ao ruído.
- Funciona bem no treino, mas erra no teste.

Modelo ajustado

- Modelo com complexidade equilibrada.
- Captura o padrão sem “decorar” os dados.

Regressão Linear

- ✓ Simples e rápida de treinar
- ✓ Fácil de interpretar (coeficientes mostram impacto de cada variável)
- ✓ Funciona bem quando a relação entre variáveis é aproximadamente linear
- ✗ Não captura relações não lineares
- ✗ Sensível a outliers (um ponto extremo pode distorcer a reta)
- ✗ Pode ter desempenho ruim em problemas reais mais complexos (R^2 baixo)

UnISENAI

Rodovia SC-401, 3730, Bairro Saco Grande, Florianópolis/SC

 3239 5745

unisenaisc.com.br



SENAI