

The background is a dark blue-tinted image of an industrial factory floor. In the center, the text 'UnISENAI' is displayed in a large, bold, sans-serif font. The 'Uni' part is light blue, and 'SENAI' is white with a blue glow. To the right of the text, there are several semi-transparent circular graphics. One circle shows '80%', another shows '79%', and a larger one shows '94%' with '01 - 1000' written below it. The overall aesthetic is modern and technological.

UnISENAI

O FUTURO COMEÇA
POR VOCÊ!

Aula 4 - Classificação

Prof. Matheus Vanzan

Machine Learning

UniSENAI

Conteúdo

- Revisão
- Algoritmos de Classificação
- Regressão Logística
- Medidas de desempenho
- KNN (*k Nearest Neighbors*)

Revisão

Revisão da Aula 3

Revisão

- Regressão Linear Simples (reta)
- Regressão Linear Múltipla (plano)
- Regressão Polinomial (curva)
- Overfitting vs Underfitting

Classificação

Definição

Classificação

- Tarefa de **prever uma categoria** (classe) a partir de **atributos**
- Saída é um rótulo **discreto** (label, classe, ...)
- Requer **dados rotulados** para treino (aprendizado supervisionado)


Classificação




Exemplos do mundo real:

- Detecção de spam (spam ou não spam)
- Diagnóstico médico (doença X ou Y)
- Reconhecimento de objeto em imagem (pessoa, carro, etc.)
- Análise de sentimentos (positivo, negativo, neutro)

Classificação



Classificação



Regressão Logística

Regressão Logística

→ Alguns algoritmos de **Regressão** também podem ser utilizados para

Classificação (*e vice-versa!*)

→ A Regressão Linear tenta ajustar uma reta aos dados

Em problemas de Classificação, uma reta pode gerar valores inválidos

- menores que 0 ou maiores que 1
- isso não pode ser interpretado como probabilidade


Regressão Logística

→ Transforma a **saída numérica** em uma **probabilidade**

→ Exemplo:


- Previsão de um email ser spam
- Saída do modelo: 0.65 👉 tem 65% de chance de ser spam 👉 spam

Regressão Logística




Regressão Logística

$$\sigma(t) = \frac{1}{1 + e^{-t}}$$



Regressão Logística

$$\sigma(t) = \frac{1}{1 + e^{-t}}$$



Regressão Logística

➡ Precisamos de um modelo que retorne **apenas** valores **entre 0 e 1**

(probabilidades)

➡ Função logística (sigmoide) 👉 sempre retorna valores entre 0 e 1

Regressão Logística


→ Precisamos de um modelo que retorne **apenas** valores **entre 0 e 1**

(probabilidades)

→ Função logística (sigmoide) 👉 sempre retorna valores entre 0 e 1

$$\sigma(t) = \frac{1}{1 + e^{-t}}$$

PRÁTICA



KNN

k-Nearest Neighbors

KNN


- KNN - k-Nearest Neighbors
- KNN é um algoritmo de **Classificação** Supervisionado
- Prevê a classe de uma nova instância com base nas **mais parecidas** (do conjunto de treino)
- Ideia: objetos com **mesmo label** tendem a ter **características semelhantes**

KNN


Descrição

1. Salvamos todos os **pontos** e seus **rótulos**
2. Para classificar um novo ponto **P**:
 - Calculamos a **distância** até todos os pontos de treino até **P**
 - Escolhemos os **k vizinhos** mais próximos
 - A classe **mais comum** entre eles é atribuída ao novo exemplo


KNN




KNN



KNN



KNN



Distâncias

Supondo o ponto $P = (x_1, x_2, \dots, x_i)$


A **Distância Euclidiana** para um ponto qualquer é dada por:

$$d(p, q) = \sqrt{\sum_{i=1}^n (p_i - q_i)^2}$$

Sendo $i = \{1, 2, 3, \dots\}$ os atributos que descrevem os pontos

Distâncias

Qual a distância entre os pontos p e q?



$$d(p, q) = \sqrt{(p_x - q_x)^2 + (p_y - q_y)^2}$$

$$d(p, q) = \sqrt{(5 - 1)^2 + (6 - 3)^2}$$

$$d(p, q) = 5$$

Distâncias

Distância Euclidiana

$$d(p, q) = \sqrt{\sum_{i=1}^n (p_i - q_i)^2}$$

Distância Manhattan (L1)

$$d(p, q) = \sum_{i=1}^n |p_i - q_i|$$

Distância de Minkowski

$$d(p, q) = \left(\sum_{i=1}^n |p_i - q_i|^p \right)^{\frac{1}{p}}$$

Escolha do valor de K

- K é o **número de vizinhos** considerados na votação
- Impacta diretamente a **performance** do algoritmo

Valores pequenos de K:

- Mais sensível a ruído (um vizinho “estranho” pode mudar a decisão)
- Fronteira de decisão mais complexa e irregular

Valores grandes de K:

- Mais estável, reduz impacto do ruído
- Pode diluir diferenças entre classes próximas
- Fronteira de decisão mais suave

Escolha do valor de K

- K é o **número de vizinhos** considerados na votação
- Impacta diretamente a **performance** do algoritmo




Regra prática: usar K ímpar para evitar empates

KNN

- ✓ Simples e intuitivo
- ✓ Não precisa de treinamento explícito
- ✓ Bom em datasets pequenos
- ✗ Lento em **grandes datasets**
- ✗ Pode precisar de **normalização** dos dados (no treino)
- ✗ Baixa performance com **alta dimensionalidade** (muitas *features*)

PRÁTICA



Medidas de Desempenho

Mediadas e Matriz de Confusão

Medidas de Desempenho

- ➔ Depois de treinar um modelo, precisamos **avaliar seu desempenho**
- ➔ Em problemas de **Classificação**, avaliamos comparando a Classe **prevista** vs Classe **real**
- ➔ A forma mais comum de organizar essa comparação é através da **Matriz de Confusão**

Medidas de Desempenho

Medida	Significado
Verdadeiro Positivo <i>True Positive</i>	modelo previu positivo , e estava certo
Falso Positivo <i>False Positive</i>	modelo previu positivo , mas estava errado (falso alarme)
Verdadeiro Negativo <i>True Negative</i>	modelo previu negativo , e estava certo
Falso Negativo <i>False Negative</i>	modelo previu negativo , mas estava errado (falhou em detectar)

Medidas de Desempenho



Exemplo (detecção de spam):

- **TP:** e-mail é spam e modelo previu spam
- **FP:** e-mail não é spam, mas modelo previu spam
- **TN:** e-mail não é spam e modelo previu não spam
- **FN:** e-mail é spam, mas modelo previu não spam

Matriz de Confusão

		Valor Predito	
		Positivo	Negativo
Real	Pos	Verdadeiro Positivo <i>True Positive</i>	Falso Negativo <i>False Negative</i>
	Neg	Falso Positivo <i>False Positive</i>	Verdadeiro Negativo <i>True Negative</i>

Matriz de Confusão

		Valor Predito	
		Positivo	Negativo
Real	Pos	Verdadeiro Positivo <i>True Positive</i>	Falso Negativo <i>False Negative</i>
	Neg	Falso Positivo <i>False Positive</i>	Verdadeiro Negativo <i>True Negative</i>

Medidas de Desempenho



Acurácia

(proporção de acertos totais)

$$\text{Acc} = \frac{TP + TN}{TP + TN + FP + FN}$$



Precisão

(quando o modelo diz “positivo”, quantas vezes ele acertou?)

$$P = \frac{TP}{TP + FP}$$



Recall

(entre todos os positivos reais, quantos o modelo encontrou?)

$$Re = \frac{TP}{TP + FN}$$



F1-score


(média harmônica de precisão e recall)

$$F1 = 2 \cdot \frac{\text{Precisão} \cdot \text{Recall}}{\text{Precisão} + \text{Recall}}$$


KFold - Validação Cruzada

- O dataset é separado em **K subconjuntos** (folds) aproximadamente iguais
- Em cada iteração, 1 fold é usado como **teste** e os demais como **treino**
- As métricas são calculadas a **para cada fold** e depois agregadas (ex: média)
- Garante avaliação **mais confiável** do modelo, evitando **depender** de uma única divisão treino/teste
- **Parâmetro K**: valores comuns são 5 ou 10 folds
 - maior K 🙌 mais robustez, mas maior custo computacional

KFold - Validação Cruzada



PRÁTICA



UniSENAI

Rodovia SC-401, 3730, Bairro Saco Grande, Florianópolis/SC

 3239 5745

unisenaisc.com.br



SENAI