

The background is a dark blue-tinted image of an industrial factory floor. In the center, the text 'UnISENAI' is displayed in a large, bold, sans-serif font. The 'Uni' part is light blue, and 'SENAI' is white. Below the main text, the phrase 'O FUTURO COMEÇA POR VOCÊ!' is written in a smaller, white, all-caps sans-serif font. On the right side of the image, there are several semi-transparent circular graphics that look like gauges or data displays. One gauge shows '80%', another shows '79%', and a larger one in the foreground shows '94%'. There are also some faint numbers like '01-1000' visible on the background elements.

UnISENAI

O FUTURO COMEÇA
POR VOCÊ!

Aula 5 - Classificação

Prof. Matheus Vanzan

Machine Learning

UniSENAI

Conteúdo

- Revisão da Aula 4
- Naive Bayes
- SVM - Support Vector Machine
- GridSearch

Revisão

Revisão da Aula 4

Revisão

- O que é Classificação?
- Regressão Logística
- KNN - K-Nearest Neighbors
- Métricas de Avaliação
- Validação Cruzada

Naive Bayes

Naive Bayes

- ➔ Modelo Supervisionado para **Classificação**
- ➔ Baseado no **Teorema de Bayes**, de distribuição probabilística
- ➔ Chamamos de ingênuo (*Naive*) porque assume que as variáveis são **independentes** entre si
- ➔ Rápido, simples e eficiente, mesmo com **grandes volumes** de dados

Naive Bayes

➔ Muito utilizado em **classificação de textos**, como:

- Detecção de spam
- Análise de sentimentos
- Categorização de documentos

Teorema de Bayes

➡ A Probabilidade evolui à medida que obtemos **novos dados**

➡ Exemplo da Jaca:

- Preciso estimar o peso de uma Jaca
- *“Acho que essa jaca deve pesar uns 2kg!”* (probabilidade a priori)
- Após sentir o peso da Jaca você ajusta sua estimativa inicial
- *“Nossa, é bem pesada! Acho que deve pesar uns 4kg!”*

Teorema de Bayes

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

- $P(A|B)$: Qual a chance de A, dado que observei B?
- $P(B|A)$: Qual a chance de observar B, assumindo que A seja verdade?
- $P(A)$: Crença inicial sobre A, antes da evidência B
- $P(B)$: Probabilidade de observar B, em qualquer situação

Teorema de Bayes

 Dados: **A = a Jaca é pesada** e **B = eu senti a Jaca pesada**

→ **P(A|B): Qual a chance de A, dado que observei B?**

*“Qual a chance da **jaca ser pesada** sabendo que **senti ela pesada**?”*

→ **P(B|A): Qual a chance de observar B, assumindo que A seja verdade?**

*“Qual a chance de eu **sentir a jaca pesada**, se **for pesada**?”*

→ **P(A): Crença inicial sobre A, antes da evidência B**

*“Qual a chance de uma jaca **ser pesada** em média no mercado?”*


→ **P(B): Probabilidade de observar B, em qualquer situação**

*“Qual a chance de **sentir uma jaca pesada** (mesmo não sendo)?”*


*Mas e o que isso tem a ver
com **Machine Learning**?*




Naive Bayes



Naive Bayes




Naive Bayes



Analogamente, estimamos as probabilidades ao longo do **eixo x_2**


Naive Bayes

$$P(x_1, x_2 | C) = P(x_1 | C) \cdot P(x_2 | C)$$



Naive Bayes

$$P(x_1, x_2 | C) = P(x_1 | C) \cdot P(x_2 | C)$$



Naive Bayes

Para 2 *features*:

Teorema de Bayes

$$P(C_k | x_1, x_2) \cdot P(x_1, x_2) = P(x_1, x_2 | C_k) \cdot P(C_k)$$

Naive Bayes

Para 2 features:



$$P(A | B) \cdot P(B) = P(B | A) \cdot P(A)$$

Teorema de Bayes

$$P(C_k | x_1, x_2) \cdot P(x_1, x_2) = P(x_1, x_2 | C_k) \cdot P(C_k)$$

Naive Bayes

Para 2 *features*:

Teorema de Bayes

$$P(C_k | x_1, x_2) \cdot P(x_1, x_2) = P(x_1, x_2 | C_k) \cdot P(C_k)$$

Simplificação “*Naive*”

$$P(x_1, x_2 | C_k) = P(x_1 | C_k) \cdot P(x_2 | C_k)$$

Naive Bayes

Para 2 features:

Teorema de Bayes

$$P(C_k | x_1, x_2) \cdot P(x_1, x_2) = P(x_1, x_2 | C_k) \cdot P(C_k)$$

Simplificação “Naive”

$$P(x_1, x_2 | C_k) = P(x_1 | C_k) \cdot P(x_2 | C_k)$$

$$P(C_k | x_1, x_2) \propto P(C_k) \cdot P(x_1 | C_k) \cdot P(x_2 | C_k)$$

Naive Bayes

Para **2 features**:

Teorema de Bayes $P(C_k | x_1, x_2) \cdot P(x_1, x_2) = P(x_1, x_2 | C_k) \cdot P(C_k)$

Simplificação “Naive” $P(x_1, x_2 | C_k) = P(x_1 | C_k) \cdot P(x_2 | C_k)$

$$P(C_k | x_1, x_2) \propto P(C_k) \cdot P(x_1 | C_k) \cdot P(x_2 | C_k)$$

Naive Bayes

→ Exemplo da previsão de spam

Email Id	x_1 Contém "promoção"	x_2 Contém "desconto"	C Classe
1	Sim	Sim	Spam
2	Sim	Não	Spam
3	Não	Sim	Spam
4	Sim	Não	Não
5	Não	Não	Não

Naive Bayes

→ Exemplo da previsão de spam

Email Id	x_1 Contém "promoção"	x_2 Contém "desconto"	C Classe
1	Sim	Sim	Spam
2	Sim	Não	Spam
3	Não	Sim	Spam
4	Sim	Não	Não
5	Não	Não	Não

$$P(\text{Spam}) = 3/5$$

Naive Bayes

→ Exemplo da previsão de spam

Email Id	x_1 Contém "promoção"	x_2 Contém "desconto"	C Classe
1	Sim	Sim	Spam
2	Sim	Não	Spam
3	Não	Sim	Spam
4	Sim	Não	Não
5	Não	Não	Não

$$P(\text{Spam}) = 3/5$$

$$P(\text{prom} | \text{Spam}) = 2/3$$

Naive Bayes

→ Exemplo da previsão de spam

Email Id	x_1 Contém "promoção"	x_2 Contém "desconto"	C Classe
1	Sim	Sim	Spam
2	Sim	Não	Spam
3	Não	Sim	Spam
4	Sim	Não	Não
5	Não	Não	Não

$$P(\text{Spam}) = 3/5$$

$$P(\text{prom} | \text{Spam}) = 2/3$$

$$P(\text{desc} | \text{Spam}) = 2/3$$

Naive Bayes

→ Exemplo da previsão de spam

Email Id	x_1 Contém "promoção"	x_2 Contém "desconto"	C Classe
1	Sim	Sim	Spam
2	Sim	Não	Spam
3	Não	Sim	Spam
4	Sim	Não	Não
5	Não	Não	Não

$$P(\text{Spam}) = 3/5$$

$$P(\text{prom} | \text{Spam}) = 2/3$$

$$P(\text{desc} | \text{Spam}) = 2/3$$

$$P(\neg \text{Spam}) = 2/5$$

Naive Bayes

→ Exemplo da previsão de spam

Email Id	x_1 Contém "promoção"	x_2 Contém "desconto"	C Classe
1	Sim	Sim	Spam
2	Sim	Não	Spam
3	Não	Sim	Spam
4	Sim	Não	Não
5	Não	Não	Não

$$P(\text{Spam}) = 3/5$$

$$P(\text{prom} | \text{Spam}) = 2/3$$

$$P(\text{desc} | \text{Spam}) = 2/3$$

$$P(\neg \text{Spam}) = 2/5$$

$$P(\text{promo} | \neg \text{Spam}) = 1/2$$

Naive Bayes

→ Exemplo da previsão de spam

Email Id	x_1 Contém "promoção"	x_2 Contém "desconto"	C Classe
1	Sim	Sim	Spam
2	Sim	Não	Spam
3	Não	Sim	Spam
4	Sim	Não	Não
5	Não	Não	Não

$$P(\text{Spam}) = 3/5$$

$$P(\text{prom} | \text{Spam}) = 2/3$$

$$P(\text{desc} | \text{Spam}) = 2/3$$

$$P(\neg \text{Spam}) = 2/5$$

$$P(\text{promo} | \neg \text{Spam}) = 1/2$$

$$P(\text{desc} | \neg \text{Spam}) = 0$$

Naive Bayes

 Se um Email contém as palavras “**promoção**” e “**desconto**”, qual a probabilidade de ser Spam?

Para Spam:

$$P(\text{Spam} | \text{prom}, \text{desc}) \propto P(\text{Spam}) \cdot P(\text{prom}, \text{Spam}) \cdot P(\text{desc}, \text{Spam}) = \frac{3}{5} \frac{2}{3} \frac{2}{3} = 0,27$$


Para não Spam:

$$P(\neg \text{Spam} | \text{prom}, \text{desc}) \propto P(\neg \text{Spam}) \cdot P(\text{promo} | \neg \text{Spam}) \cdot P(\text{desc} | \neg \text{Spam}) = \frac{2}{5} \frac{1}{2} 0 = 0$$



O modelo classifica como **Spam**

PRÁTICA




SVM

Support Vector Machine

SVM - Support Vector Machine


- ➔ Modelo Supervisionado para **Classificação** e **Regressão**
- ➔ Encontra o **hiperplano** que **maximiza** a margem
- ➔ Vetores de suporte são os pontos que **definem** a fronteira
- ➔ Pode ser linear ou não linear via **kernel**

SVM




SVM

🤔 e se as amostras não forem linearmente separáveis?




SVM

🤔 e se as amostras não forem linearmente separáveis?




SVM

🤔 e se as amostras não forem linearmente separáveis?




SVM



SVM

- ➔ Objetivo: encontrar a fronteira que maximiza a margem
- ➔ Parâmetros:
 - **C** (penalidade a erros): C pequeno: mais margem e mais tolerância a erros; C grande: menos margem, foca em acertar o treino
 - **Kernel** (separação não linear): função de similaridade que permite fronteiras curvas

PRÁTICA



UnISENAI

Rodovia SC-401, 3730, Bairro Saco Grande, Florianópolis/SC

 3239 5745

unisenaisc.com.br



SENAI